

CONTEXTE

Dans le cadre de ma *formation Data Analyst (2024)*, il nous a été demandé de réaliser un projet collaboratif.

Ayant choisi une reconversion dans le monde de la Data, je me suis tout naturellement tournée vers un sujet me tenant à cœur : établir un profilage des métiers de ce secteur d'activité. A travers ce rapport, établi *sur la base de sondages Kaggle*, j'ai pu découvrir de manière plus approfondie ce milieu très spécifique et technique, vers lequel j'ai décidé de m'orienter. Lors de notre travail commun, nous avons obtenue une accuracy (métrique évaluant les performances de modèles prédictifs) de 0.42. J'ai repris le projet en le consolidant (ajout des sondages 2018 et 2019, sélection de données différentes), ce qui m'a permis d'accroître la performance de mon modèle de prédiction.

PROJET DATA

Ce projet se base sur *la collecte et l'analyse de sondages Kaggle annuels sur la plage 2018 / 2022*, regroupant les réponses de plus de 20 000 participants.

Nous nous attacherons à mettre en relief les *caractéristiques techniques*, les *outils* ainsi que les *compétences* propres à *4 métiers* du monde de la Data: *DataAnalyst, DataScientist, ResearchScientist SoftwareEngineer*.

Pour chaque poste, nous aborderons en premier lieu les bases essentielles aux actifs de la Data:

- les principaux *langages de programmation*
- les *notebooks* pouvant être utilisés pour réaliser le codage
- les principales *bibliothèques de visualisations graphiques* des données
- les principaux *logiciels de reporting* usités pour une présentation de pointe, simple et claire, des résultats d'analyses

Nous nous concentrerons par la suite sur le *Machine Learning*, branche de l'IA consistant au développement d'algorithmes et de modèles statistiques permettant aux ordinateurs de réaliser des tâches complexes et chronophages en toute autonomie.

- les *algorithmes mathématiques* les plus utilisés
- les moyens d'*automatisation à grande échelle* de ces modèles statistiques

Nous poursuivrons par l'étude des *environnements de travail intégrés*, IDE, logiciel regroupant en une seule interface l'ensemble des outils nécessaires à la création d'applications.

Enfin, nous terminerons par la *Computer Vision*, branche de l'IA visant à l'extraction des caractéristiques propres d'images, de vidéos ...

En intégrant ces données dans des modèles informatiques, les ordinateurs peuvent traiter, par analyse comparative, des informations en masse de manière plus précise et rapide que l'humain

POST-SCRIPTUM

Notons que les données concernant certaines compétences ne sont pas toujours renseignées dans les sondages les plus anciens. Cela s'explique par l'évolution des questions posées, reflétant un monde de la data en constante évolution..

REALISATIONS



ACTIONS

Collecte de data

- Etude réalisée entre 2018 et 2022
- BDD de référence : <https://www.kaggle.com/c/kaggle-survey-2020/overview>
- Dataset 2018 **43 Mo**
- Dataset 2019 **22 Mo**
- Dataset 2020 **26 Mo**
- Dataset 2021 **35 Mo**
- Dataset 2022 **26 Mo**

Preprocessing général sur notebook


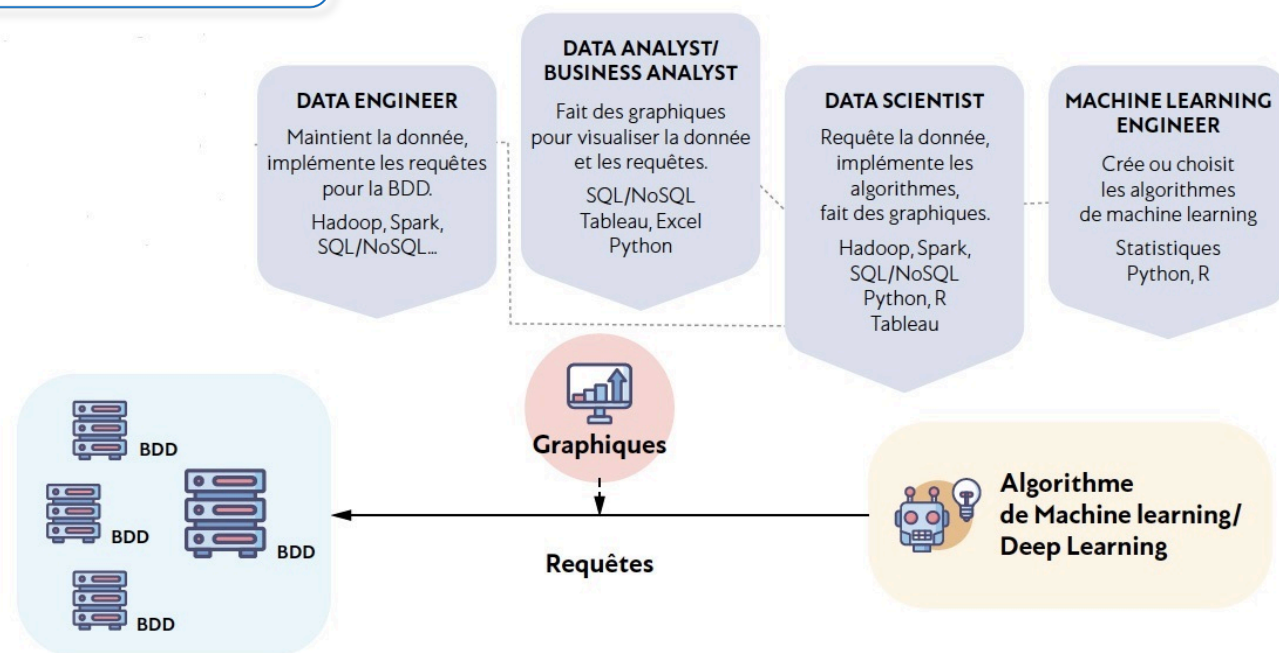
- Filtrations des données sur les 4 métiers les plus représentés
- Restriction du nombre de colonnes (350) de moitié par choix de variables pertinentes
- Regroupement des modalités, de 11 à 4, notamment sur la variable Age
- Chargement sur Power Bi pour affinage du cleaning

Data Cleaning en détails via Power Query

- Uniformisation des colonnes, noms, types
- Normalisations des modalités pour futures mesures DAX
- Mises en place de relations entre les tables
- Création de visuels interactifs
- Etablissement de filtrations dynamiques, de widgets ...

Mise en place d'un rapport interactif présentant les résultats d'analyses

PRESENTATION DES METIERS



DATA ANALYST

Le DataAnalyst est chargé de *l'extraction* et de *l'analyse* des données afin d'aider les équipes dirigeantes à prendre des *décisions stratégiques*.

Il valorise les données en établissant des *modèles statistiques* et *prédictifs* (Machine Learning), ainsi que des *tableaux de bord* mettant en relief des *indicateurs de performances* nécessaires au *management de l'entreprise*.

DATA SCIENTIST

Le DataScientist est chargé de *construire des modèles statistiques* et *algorithmiques* à partir de données existantes afin de mieux comprendre la Data et de *prédire les phénomènes futurs*.

Spécialiste du *Machine Learning en masse* (DeepLearning), il s'orientée vers la *construction* et le *déploiement* de *modèles IA*.

SOFTWARE ENGINEER

Le SoftwareEngineer est un *professionnel du Machine Learning* qui *développe* et *implémente* des *algorithmes* et des *modèles* d'apprentissage automatique dans des applications logicielles.

Il est chargé de concevoir et de *créer des applications logicielles* capables d'apprendre à partir de données et de faire des *prédictions* ou de *prendre des décisions en fonction de ces données*.

RESEARCH SCIENTIST

Un ResearchScientist *conçoit, réalise et analyse* des informations issues *d'expériences, d'essais* et *d'enquêtes* de la vie courante. Il est chargé de mener des *recherches*, de *développer* de *nouveaux algorithmes* et *modèles*, de tester leur efficacité pour *résoudre des problèmes du monde réel*.

Les chercheurs scientifiques sont généralement employés dans des *universités*, des *instituts de recherche* ou de *grandes entreprises technologiques* (recherche médicale, pharmacologie, géosciences...)

PRESENTATION DES JEUX DE DONNEES

DataAnalyst

DataScientist

ResearchScientist

SoftwareEngineer

2018


2019

2020

2021


2022

Répartition des sondés



Sur la période nous observons que les datasets sont fortement orientés vers le métier de DataScientist.

Sexe des sondés



Les métiers du numérique sont essentiellement occupés par une population masculine. En 2024, une étude de l'INSEE confirme cette tendance.

Evolution de l'âge des actifs


2018

18 à 29 ans 36,54 % 45 à 59 ans 6,51 % 60 ans et + 1,07 %


2022

18 à 29 ans 44,47 % 45 à 59 ans 14,49 % 60 ans et + 3,42 %

Si en 2018 le secteur de la data compte plus de 55% de jeunes actifs, il s'est fortement démocratisé depuis.



Niveau de formation des sondés



Un niveau Bachelor (bac +3) ou Master (bac +5) ouvrent les portes de la majeure partie des emplois dans la DataScience. Les postes de pointe tels que celui de ResearchScientist nécessitent des études plus poussées.

GLOSSAIRE



LANGAGES DE PROGRAMMATION

Langages informatiques permettant d'*écrire un code source* qui sera *ensuite analysé par une machine* (un ordinateur).

Ce code source subit ensuite une évaluation ou une transformation dans une forme exploitable par l'ordinateur.

Python langage de *base* pour la *programmation*

SQL langage de requêtes structurées / *gestion de base de données relationnelles* (données organisées en tables) et de leur *flux*

R langage utilisé pour le *calcul statistique*

Java/Javascript langage pour le *codage des applications web*, la *création de jeux vidéos*, de *sites web interactifs et dynamiques*

C/C++/C# langage de programmation pour la *création d'applications web en temps réel* et de *systèmes embarqués*

NOTEBOOKS ("calepin électronique", environnement de travail des codeurs)

Les notebooks sont des *interfaces de programmation interactives*, utilisées pour *explorer* et *analyser* des données, qui par la suite sont enregistrées sous forme de documents.

Leur usage en data science permet de *faciliter le partage* et la *reproductibilité des résultats*.

Le *choix* de l'un ou l'autre dépend de l'*affinité du codeur* ainsi que du *travail à accomplir*.

GLOSSAIRE



LIBRAIRIES OPENSOURCE POUR LA VISUALISATION DES RESULTATS D'ANALYSE DES DONNEES

Matplotlib *données 2D* polyvalentes pour créer des *graphiques statiques* (finance, recherche scientifique, marketing ...)

Seaborn *surcouche de matplotlib* pour des graphiques plus esthétiques et attrayants

Plotly graphiques de *haute qualité* pour les sites web (données 3D, diagrammes de réseau...)

Ggplot basée sur la *grammaire des graphiques*, pour la visualisation de *data complexes*

TABLEAUX DE BORD (report)

Présentation et organisation des *informations et résultats d'analyse* de manière claire et facile à comprendre, au moyen de *visualisations graphiques*.

Ce rapport a pour but de *faciliter la prise de décision éclairée* (indicateurs de performances, évolution du chiffre d'affaire...)

LOGICIELS DE REPORTING

Le *reporting*, rapport d'activité, permet de *mettre en scène des données* et de les *présenter de manière claire* afin qu'elles puissent être *analysées et exploitées* par une tierce personne. C'est un outil des plus efficace dans *l'aide à la prise de décision*.

Power BI Facilite la *connexion*, *l'extraction*, la *transformation* ainsi que les *visualisations* à partir de data pré-nettoyée

Tableau *Simplifie* et *rend intelligible* les *données brutes*

DataStudio *Centraliser* dans *un seul et unique fichier* en ligne *différentes sources* de *données statistiques*

Quicksight Dédié aux entreprises de toutes tailles nécessitant une *solution d'apprentissage automatique pour gérer leurs clients et leurs opérations*

GLOSSAIRE

MACHINE LEARNING (APPRENTISSAGE AUTOMATIQUE)

Champ d'étude de l'IA visant à donner aux *machines la capacité* d'« *apprendre* » à partir de données, via des modèles mathématiques.


ALGORITHMES DE MACHINE LEARNING

Ensemble de *règles* ou de *processus utilisés par un système d'IA* pour effectuer des tâches qui seraient longues et complexes pour un humain.

Ils sont utilisés pour *prédire les valeurs de sortie* à partir d'un ensemble de variables, *découvrir de nouvelles informations* dans les bases de données, ainsi que pour *l'établissement de modèles de données* plus efficaces (Un modèle de données définit et structure l'ensemble des données d'une entreprise ainsi que leurs connexions dans le cadre de process métiers précis.


Régression linéaire Algorithme d'apprentissage automatique utilisé pour *prédire les valeurs des variables de sortie en fonction des valeurs des variables d'entrée*.

Lors de ce calcul une ligne droite est tracée au milieu d'un nuage de points qui représente les valeurs d'entrées. Plus les points se rapprochent de la ligne, plus le modèle statistique sera performant.



Régression logistique Algorithme d'apprentissage automatique utilisé pour *classifier les valeurs de sortie en fonction des valeurs des variables d'entrée*.


Lors de ce calcul mathématique, seules 2 alternatives sont envisagées: OUI ou NON




GLOSSAIRE

ALGORITHMES DE MACHINE LEARNING

Random forest La forêt d'arbres décisionnels est un algorithme de machine learning qui *combine les résultats de plusieurs arbres de décision pour obtenir un résultat unique*. Elle est ainsi constituée d'un ensemble d'arbres de décision.




Gradient boosting Algorithme *d'optimisation* qui *combine un ensemble de modèles faibles* en *un seul modèle prédictif plus précis et plus efficace*.




GLOSSAIRE

ALGORITHMES DE MACHINE LEARNING

Réseaux neuronaux convolutifs Algorithme utilisant des *données tridimensionnelles* pour des tâches de *classification d'images* et de *reconnaissance d'objets*, mais aussi la *découverte de médicaments*, *l'évaluation des risques pour la santé*...



Réseaux neuronaux récurrents Algorithme entraîné sur des *données séquentielles* ou *de séries temporelles* afin de créer un *modèle de ML* capable de *tirer des prédictions séquentielles* ou *des conclusions* sur la base d'entrées séquentielles. Il est utilisé notamment pour la *reconnaissance vocale*, le *diagnostic médical*, la *robotique*...



GLOSSAIRE

MACHINE LEARNING AUTOMATISE

Processus d'automatisation des *tâches itératives* et *chronophages* du développement de modèles d'apprentissage automatique, permettant aux data scientists, analystes et développeurs de créer des *modèles ML* à *grande échelle*, avec une *efficacité* et une *productivité élevées*, tout *en préservant la qualité du modèle*.

Il se base sur des « *plateforme cloud* » (système d'exploitation et matériel des serveurs, comme les logiciels, les bases de données, les réseaux ...) *assurant aux utilisateurs finaux un service de cloud computing* quelque soit *leur localisation dans le monde*.



Azure Plateforme cloud de Microsoft offrant un service d'analyse complet qui intègre le *Big Data* et l'*entreposage de données* en un seul et unique lieu du cloud.

Elle est principalement axée sur l'*intégration* et la *sécurité des données*, ce qui la rend très efficace pour répondre aux besoins des data scientists, des développeurs et des entreprises qui cherchent à *faire évoluer efficacement leurs flux de travail ML*.



Databricks Plateforme d'analyse de données conçue pour le traitement du *Big Data*, l'*apprentissage automatique à grande échelle* et l'*IA*. Elle est particulièrement adaptée aux organisations ayant des *besoins complexes en science des données et en ingénierie*.



DataRobot Plateforme qui se concentre sur l'*apprentissage automatique* et la *création de modèles automatisés*. Idéale pour les organisations qui cherchent à *développer* et à *déployer rapidement* des *modèles d'apprentissage automatique sans expertise technique approfondie*.



Amazon SageMaker

Sagemaker Plateforme cloud d'Amazon entièrement gérée qui permet aux développeurs et aux data scientists de *créer, former* et *déployer rapidement* et *facilement* des *modèles de machine learning* à *n'importe quelle échelle*. Elle est très efficace dans la *gestion de données* et l'*apprentissage*.



Cloud AutoML Vision

Google cloud Plateforme cloud Microsoft qui propose une *suite d'outils* et de *services d'apprentissage automatique* conçus pour aider les développeurs et les data scientists à *créer et déployer des modèles ML*.



H2O Solution de machine learning en open source afin d'aider les entreprises en *gérant la publicité en ligne*, la *gestion des réclamations*, la *détection des fraudes* ... *une analyse*.

GLOSSAIRE



IDE(environnement de développement intégré)

Les IDE sont des *applications logicielles combinant au même endroit tous les outils nécessaires* à un projet de développement logiciel.

Ils fournissent une interface permettant d'*écrire du code*, d'*organiser des groupes de texte*, et d'*automatiser les tâches redondantes de programmation*.

Le *choix* de l'un ou l'autre dépend de l'*affinité du codeur* ainsi que du *travail à accomplir*.

RStudio Utilisé pour le codage en *R* et *Python*.

VSCode Utilisé pour le *codage de production* et le *débogage* (logiciel aidant un *développeur* à analyser les *bugs* d'un *programme*).

Jupyter Analyses et les *prédictions*. Idéal pour la *visualisation* et la *création de modèles*

PyCharm IDE dédié aux programmeurs *Python*, ainsi que *JavaScript*

Sublime Text Pour le *codage régulier* et *rapide* car léger.

COMPUTER VISION

Domaine de *l'intelligence artificielle (IA)* qui utilise le machine learning et les réseaux neuronaux pour apprendre aux ordinateurs et aux systèmes à *dériver des informations significatives à partir d'images numériques, de vidéos et d'autres entrées visuelles*, dans le *but de faire des recommandations ou prendre des mesures lorsque des défauts ou des problèmes sont identifiés*.

TrackingVideo Outil permettant de *détecter* puis de *suivre la position* d'un objet *dans une image* et d'*enregistrer sa position image par image* afin de *définir une trajectoire*. Il est alors possible d'*appliquer cette trajectoire à un autre objet* afin que celui-ci possède le même mouvement (systèmes de vidéosurveillance, le sport...)


ImageSegmentation Outil de *traitement d'images* qui utilise des *méthodes mathématiques simples* (dérivée, gradient...) afin de *détecter et rassembler les pixels d'une image* suivant des critères, notamment d'intensité ou spatiaux. Le model *détecte ainsi tous les points* et *reconstruit les contours en les liants* (imagerie médicale, analyse d'images satellitaires, voitures autonomes...)

ImageClassification Méthode reposant sur des *algorithmes sophistiqués* capables *d'analyser* et de *déduire* des *informations à partir d'images numériques*, qu'il s'agisse de distinguer des objets, d'identifier des motifs ou de reconnaître des scènes complexes (contrôle qualité, la détection des défauts, la surveillance, la reconnaissance faciale...)

GenerativeNeuralNetworks Technique ayant comme objectif de *produire du contenu sous certaines conditions définies au préalable*. Les modèles sont entraînés à *générer des données d'après une base de données réelles comme référence*, et un *mécanisme de validation* qui permet à l'algorithme apprenant d'évaluer la qualité des données générées, en se basant sur le référent.

ObjectDetection Outil dont l'objectif est de *détecter et de localiser des objets d'intérêt dans une image ou une vidéo*. La tâche consiste à *identifier la position et les limites des objets dans une image* et à *classer les objets en différentes catégories*. (surveillance des cultures, surveillance du trafic routier, reconnaissance biométrique...)

LES COMPETENCES REQUISES DATA ANALYST



Hard Skill Data Analyse

- Savoir interpréter la donnée
- Power Bi, Tableau, Qlik, Looker studio (Outils de Data Visualisation)
- SQL et NoSQL pour le requêtage sur base de données
- Avoir une compréhension globale du Modern Data Stack

Soft Skill Humain

- Savoir présenter ses conclusions
- Pouvoir collaborer et éduquer avec pédagogie ses collègues à l'écosystème data
- Savoir faire une synthèse de son travail pour ses supérieurs
- Avoir un esprit critique


EVOLUTION DES COMPETENCES DATA ANALYST

2018 2019 2020 2021 2022

1-Principaux langages de codage

Année	SQL	Java/Script	R	C
2022	30,4 %	7,7 %	12,5 %	5,9 %
2021	28,1 %	9,4 %	14,0 %	5,8 %
2020	27,0 %	9,0 %	15,3 %	6,4 %
2019	28,2 %	7,0 %	19,4 %	3,4 %
2018	26,8 %	8,7 %	21,8 %	5,7 %

2-Calepins de codage les plus usités




5-Algorithmes de Machine Learning

RéseauxNeuronaux Tree/Forest Gradient Boosting Regression




6-Plateformes cloud de Machine Learning automatisé




Outre Python, langage de base de tout codage, les Data Analyst **maîtrisent largement SQL**, ce qui leur permet de comprendre facilement les relations entre différentes données structurées sous forme de tables. Les **notebooks** sont quant à eux à **l'appréciation** des codeurs. Notons tout de même une **baisse significative de l'usage de Jupyter, au profit de GoogleColab et Kaggle**, calepins très performants lors **des projets collaboratifs**.

De par leur nécessité prédictive généraliste, les Data Analyst ont recouru à des **algorithmes "simples"**, tel que la **Régression**, les **Arbres** ou **Forêts**. Pour **l'automatisation** de ces prédictions, ils préfèrent employer **GoogleCloud**, qui domine largement.

3-Librairies de visualisation des données




4-Principaux logiciels de reporting




Matplotlib et **Seaborn**, de par leur simplicité d'utilisation, **dominent largement dans le secteur de la visualisation de données**. Ces **représentations graphiques des résultats d'analyse** sont par la suite **insérées dans des rapports** permettant la **prise de décisions**. **Tableau** et **Power BI**, très intuitifs, sont les logiciels les plus appréciés.

7-Evolution des environnements de développement



8-Principaux outils d'analyse visuelle



Les DataAnalyst, dont le rôle principal consiste à collecter, analyser et présenter les résultats au moyen de rapports graphiques, utilisent **à forte majorité l'IDE Jupyter**, parfaitement adapté à leurs nécessités métier. N'étant pas spécialistes des réseaux neuronaux, ils ont ainsi recouru à des **outils de base pour la détection d'image; la segmentation et la classification**.

LES COMPETENCES REQUISES

DATA SCIENTIST



Hard Skill Data Science

- Statistiques Prédictives
- Mathématiques
- Statistiques inférentielles
- Modélisation statistique
- Probabilités
- Maîtrise de plusieurs langages de programmation (Python, R, SQL etc...)
- Machine Learning
- Data Mining et Web Scraping

Soft Skill Humain

- Capacité à écouter et à comprendre les besoins des clients
- Travailler en équipe avec ses collaborateurs
- Adaptabilité et apprentissage continu
- Savoir faire une synthèse de son travail pour ses supérieurs
- Avoir un esprit critique


EVOLUTION DES COMPETENCES DATA SCIENTIST

2018 2019 2020 2021 2022


1-Principaux langages de codage

Année	SQL	Java/Script	R	C
2022	23,3 %	9,3 %	10,1 %	7,0 %
2021	20,3 %	11,0 %	10,6 %	9,5 %
2020	19,9 %	10,6 %	12,0 %	8,6 %
2019	23,1 %	8,1 %	16,5 %	4,5 %
2018	20,7 %	8,8 %	17,6 %	6,1 %


2-Calepins de codage les plus utilisés




3-Librairies de visualisation des données




4-Principaux logiciels de reporting




5-Algorithmes de Machine Learning




6-Plateformes cloud de Machine Learning automatisé



7-Evolution des environnements de développement



8-Principaux outils d'analyse visuelle




Le profil des DataScientist est assez similaire à celui des DataAnalyst.

Notons tout de même une **préférence de GoogleColab** pour leur **environnement de travail**.

Plus spécialisés en Machine Learning prédictif concernant l'étude et le traitement d'images, objets et vidéos, ils **utilisent plus couramment les outils de détection d'objets**.

LES COMPETENCES REQUISES SOFTWARE ENGINEER



Hard Skill Data Engineering

- Coder au travers de différents langages de programmation
- Concevoir et gérer des bases de données
- Modéliser des données
- Appliquer des concepts de machine learning
- Gérer un projet et un pipeline de données

Soft Skill Humain

- Communiquer de manière claire et efficace
- Travailler en équipe avec ses collaborateurs
- S'adapter au changement et être résilient
- Être organisé
- Avoir un esprit critique

EVOLUTION DES COMPETENCES SOFTWARE ENGINEER

2018

2019

2020


2021

2022


1-Principaux langages de codage

Année	SQL	Java/Script	R	C
2022	19,5 %	25,7 %	2,7 %	15,9 %
2021	19,0 %	29,3 %	2,3 %	12,9 %
2020	18,8 %	29,6 %	3,0 %	12,4 %
2019	17,4 %	26,1 %	5,1 %	10,0 %
2018	15,7 %	26,9 %	4,8 %	15,1 %


2-Calepins de codage les plus utilisés



3-Librairies de visualisation des données




4-Principaux logiciels de reporting




5-Algorithmes de Machine Learning




6-Plateformes cloud de Machine Learning automatisé



7-Evolution des environnements de développement



8-Principaux outils d'analyse visuelle



Le Software Engineer est un spécialiste de la création d'applications logicielles.

En ce sens il **maîtrise largement les langages Java/JavaScript**.

Il se distingue par un **usage approfondi de Sagemaker** au niveau des outils de Machine Learning automatisés, ainsi que dans la détection d'objets vidéos.

LES COMPETENCES REQUISES
RESEARCH SCIENTIST

Tech Skills

- ▶ Machine Learning
- ▶ Data Science
- ▶ AI Frameworks & Tools
- ▶ Programming Languages
- ▶ Algorithm Design
- ▶ Algorithm Optimization

Soft Skills

- ▶ Adaptability
- ▶ Communication Skills
- ▶ Attention to Detail
- ▶ Problem- Solving Skills
- ▶ Critical Thinking

EVOLUTION DES COMPETENCES SOFTWARE ENGINEER

2018

2019

2020


2021

2022


1-Principaux langages de codage

Année	SQL	Java/Script	R	C
2022	9,7 %	9,3 %	12,9 %	13,6 %


2-Calepins de codage les plus utilisés



3-Librairies de visualisation des données




4-Principaux logiciels de reporting




5-Algorithmes de Machine Learning




6-Plateformes cloud de Machine Learning automatisé



7-Evolution des environnements de développement



8-Principaux outils d'analyse visuelle



Expert de l'analyse de données en temps réel, le ResearchScientist se doit de maîtriser le **langage R**, **calcul statistique**, ainsi que le **codage en C** afin de réaliser des **applications web de résultats instantanés**. Ils ont une appétence particulière pour le **notebook GoogleColab**, calepin de partage très efficace.

CONCLUSION



A travers cette étude nous observons que l'ensemble des métiers de la datascience développent un large tronc commun.

Les profils de **DataAnalyst** et **DataScientist**, plus « généralistes », *sont assez similaires*.

- Une maîtrise essentielle des *langages Python et SQL*, ainsi que de *notions en R*
- Un recours préférentiel à *Matplotlib* et *Seaborn* dans l'établissement des rapports graphiques
- L'usage en *Machine Learning d'algorithmes, de plateformes d'automatisation « simples »* (tout de même un peu plus complexes pour les DataScientist)
- Un emploi majoritaire des méthodes de *classifications* et *segmentation* dans l'*analyse visuelle*

Le **SoftwareEngineer**, dont le rôle majeur consiste à créer des applications logicielles et web interactives, *code essentiellement en Java/Javascript*.

Ses nécessités métier en *Machine Learning automatisé*, le pousse à utiliser préférentiellement *Sagemaker*.

En effet cette plateforme lui assure une *création* ainsi qu'un *déploiement rapide* et *facile* de ses modèles prédictifs, nécessaire à l'*apprentissage à grande échelle des ordinateurs*.

Expert de l'analyse de données en temps réel, le **ResearchScientist** a une forte appétence dans le *codage en R (calcul statistique)*, ainsi qu'en *C (applications web aux résultats instantanés)*

Ses besoins en Machine Learning prédictif à grande échelle et instantané, le poussent à faire usage d'*algorithmes complexes, réseaux neuronaux*, ainsi que de *plateformes d'automatisation et d'analyse à hautes performances*.

Notons aussi que le **monde de la data est en perpétuel mouvement**.

Afin de répondre aux demandes "clients" de plus en plus spécifiques, dans un but de simplification et valorisation des performances, de *nombreux outils, méthodes* sont conçus et *mis régulièrement à la disposition des codeurs, développeurs ...*

D'où une *faculté nécessaire* des acteurs de la Data à l'*adaptation* ainsi à la *formation en continue*.

Enfin, il est important de relever une **spécialisation des métiers de datascience**, dans un *souci de gain de temps, de valorisation et d'accessibilité aux données*, mais aussi et surtout afin de *pousser de plus en plus loin le champ des possibles en totale adaptation aux nécessités entreprises, comportementales, sociétales*